

Dense baseline (naive, seq=512, bs=32, fp32)

Task	Metric	Dense score	Latency (ms)	Throughput (samples/s)	Peak mem infer (MB)
CoLA	MCC	0.533877	120.34	262.6	987.2
SST-2	Acc	0.924312	110.74	281.2	987.2
MRPC	F1	0.913495	112.40	279.2	987.2
QQP	F1	0.878181	127.00	251.9	987.2
MNLI-m	Acc	0.845848	125.74	254.3	987.2
QNLI	Acc	0.915431	125.51	254.5	987.2
RTE	Acc	0.725632	111.82	275.2	987.2
STS-B	Pearson	0.880462	119.64	266.7	987.2
G-AVG	—	0.8272	119.1	265.7	987.2
A-AVG	Acc(4)	0.8528	—	—	—

注：为何 Dense 987 MB 而压缩 Naive 约 2004 MB？ HF BERT 在 PyTorch ≥ 2.0 下默认走 SDPA 融合路径，不物化 [B,H,M,M] logits 与 attention weights；压缩 Naive(einsum) backend 显式计算这两个矩阵（各 ≈ 384 MB，合计 ≈ 768 MB 额外开销）。这是 kernel 实现差异，非对比不公平。FlashSVD (~708 MB) 才是与 Dense 同水位的公平对比。详见 Issues_found.md #19。

压缩未微调 (naive backend, per-head ra48) ——精度对比 + Δ vs Dense

Task	Dense	SVD	Δ	FWSVD	Δ	DRONE	Δ	AdaSVD	Δ
CoLA (MCC)	0.533877	0.026364	-0.5075	0.144358	-0.3895	0.015667	-0.5182	0.002035	-0.5318
SST-2 (Acc)	0.924312	0.717890	-0.2064	0.777523	-0.1468	0.855505	-0.0688	0.613532	-0.3108
MRPC (F1)	0.913495	0.000000	-0.9135	0.371968	-0.5415	0.847244	-0.0663	0.000000	-0.9135
QQP (F1)	0.878181	0.171670	-0.7065	0.680015	-0.1982	0.762204	-0.1160	0.515351	-0.3628
MNLI-m (Acc)	0.845848	0.373510	-0.4723	0.522262	-0.3236	0.578706	-0.2671	0.348650	-0.4972
QNLI (Acc)	0.915431	0.546403	-0.3690	0.573311	-0.3421	0.602050	-0.3134	0.458356	-0.4571
RTE (Acc)	0.725632	0.472924	-0.2527	0.584838	-0.1408	0.595668	-0.1300	0.534296	-0.1913
STS-B (Pearson)	0.880462	0.352223	-0.5282	0.693440	-0.1870	0.492980	-0.3875	0.636666	-0.2438
G-AVG	0.8272	0.3326	-0.4945	0.5435	-0.2837	0.5938	-0.2334	0.3886	-0.4385
A-AVG	0.8528	0.5277	-0.3251	0.6145	-0.2383	0.6580	-0.1948	0.4887	-0.3641

压缩后微调 (post-compress finetune, per-head ra48) ——精度对比 + Δ vs 对照基线

Task	Base (Dense or Dense_finetuned)	SVD-ft	Δ	FWSVD-ft	Δ	DRONE-ft	Δ	AdaSVD-ft	Δ
CoLA (MCC)	0.578332	0.374585	-0.2037	0.471691	-0.1066	0.431304	-0.1470	0.410800	-0.1675
SST-2 (Acc)	0.925459	0.910550	-0.0149	0.904817	-0.0206	0.908257	-0.0172	0.916284	-0.0092

Task	Base (Dense or Dense_finetuned)	SVD-ft	Δ	FWSVD-ft	Δ	DRONE-ft	Δ	AdaSVD-ft	Δ
MRPC (F1)	0.913495	0.843333	-0.0702	0.885522	-0.0280	0.901893	-0.0116	0.884746	-0.0287
QQP (F1)	0.878181	0.872762	-0.0054	0.873900	-0.0043	0.872570	-0.0056	0.874060	-0.0041
MNLI-m (Acc)	0.845848	0.820071	-0.0258	0.827305	-0.0185	0.820071	-0.0258	0.823332	-0.0225
QNLI (Acc)	0.915431	0.889072	-0.0264	0.891085	-0.0243	0.893282	-0.0221	0.891818	-0.0236
RTE (Acc)	0.725632	0.613718	-0.1119	0.646209	-0.0794	0.740072	+0.0144	0.595668	-0.1300
STS-B (Pearson)	0.880462	0.865878	-0.0146	0.869957	-0.0105	0.848666	-0.0318	0.872942	-0.0075
G-AVG	0.8329	0.7737	-0.0591	0.7963	-0.0365	0.8020	-0.0308	0.7837	-0.0491
A-AVG	0.8531	0.8084	-0.0448	0.8174	-0.0357	0.8404	-0.0127	0.8068	-0.0463

System Performance (per-head ra48, seq=512, bs=32, fp32)

格式: Naive = lat(ms)/thr(sps)/mem(MB), Flash = 同格式

Task	Method	Naive	Flash	Speedup	Memory Change
CoLA	SVD	161/196/2004	92/348/708	x1.75	-1296 MB (-64.7%)
CoLA	FWSVD	158/200/2011	95/338/708	x1.67	-1303 MB (-64.8%)
CoLA	DRONE	163/194/2004	94/339/708	x1.73	-1296 MB (-64.7%)
CoLA	AdaSVD	166/190/2522	101/317/725	x1.65	-1797 MB (-71.3%)
SST-2	SVD	160/195/2004	91/352/708	x1.75	-1296 MB (-64.7%)
SST-2	FWSVD	157/198/2011	93/345/708	x1.69	-1303 MB (-64.8%)
SST-2	DRONE	161/194/2004	93/345/708	x1.73	-1296 MB (-64.7%)
SST-2	AdaSVD	164/190/2516	99/322/722	x1.65	-1794 MB (-71.3%)
MRPC	SVD	161/194/2004	94/342/708	x1.72	-1296 MB (-64.7%)
MRPC	FWSVD	158/199/2011	93/344/708	x1.70	-1303 MB (-64.8%)
MRPC	DRONE	162/193/2004	94/342/708	x1.73	-1296 MB (-64.7%)
MRPC	AdaSVD	166/189/2523	100/319/725	x1.66	-1797 MB (-71.3%)
QQP	SVD	166/192/2004	100/319/708	x1.66	-1296 MB (-64.7%)
QQP	FWSVD	162/197/2011	101/316/708	x1.60	-1303 MB (-64.8%)
QQP	DRONE	167/192/2004	102/314/708	x1.64	-1296 MB (-64.7%)
QQP	AdaSVD	169/189/2519	107/299/723	x1.58	-1796 MB (-71.3%)
MNLI-m	SVD	166/193/2004	100/320/708	x1.66	-1296 MB (-64.7%)
MNLI-m	FWSVD	162/198/2011	100/321/708	x1.62	-1303 MB (-64.8%)
MNLI-m	DRONE	166/193/2004	100/320/708	x1.66	-1296 MB (-64.7%)

Task	Method	Naive	Flash	Speedup	Memory Change
MNLI-m	AdaSVD	168/190/2516	102/313/724	x1.64	-1792 MB (-71.3%)
QNLI	SVD	166/193/2004	99/323/708	x1.67	-1296 MB (-64.7%)
QNLI	FWSVD	161/198/2011	99/325/708	x1.64	-1303 MB (-64.8%)
QNLI	DRONE	166/193/2004	99/325/708	x1.68	-1296 MB (-64.7%)
QNLI	AdaSVD	168/190/2515	101/315/721	x1.66	-1794 MB (-71.3%)
RTE	SVD	161/191/2004	93/346/708	x1.74	-1296 MB (-64.7%)
RTE	FWSVD	156/197/2011	93/345/708	x1.68	-1303 MB (-64.8%)
RTE	DRONE	160/192/2004	93/346/708	x1.73	-1296 MB (-64.7%)
RTE	AdaSVD	164/188/2515	98/326/721	x1.67	-1794 MB (-71.3%)
STS-B	SVD	165/194/2004	96/335/708	x1.72	-1296 MB (-64.7%)
STS-B	FWSVD	160/199/2011	96/335/708	x1.67	-1303 MB (-64.8%)
STS-B	DRONE	165/194/2004	96/335/708	x1.72	-1296 MB (-64.7%)
STS-B	AdaSVD	168/190/2524	103/311/726	x1.63	-1799 MB (-71.3%)



SDPA 消融（三档对比）：Naive(einsum) → Naive(SDPA) → FlashSVD(Triton)


测试条件：per-head ra48, seq=512, bs=32, fp32, 8 tasks 平均（跳过精度评估，仅测吞吐/内存）

Method	Naive-einsum (ms/sps/MB)	Naive-SDPA (ms/sps/MB)	FlashSVD (ms/sps/MB)	einsum→SDPA	SDPA→Flash	Flash vs einsum mem	Flash vs SDPA mem
SVD	163/194/2004	91/349/1566	96/336/708	x1.79	x0.95	-64.7%	-54.8%
FWSVD	159/198/2011	91/346/1566	96/333/708	x1.75	x0.95	-64.8%	-54.8%
DRONE	164/193/2004	92/344/1566	96/333/708	x1.78	x0.96	-64.7%	-54.8%
AdaSVD	167/190/2519	95/332/1588	102/315/723	x1.76	x0.93	-71.3%	-54.5%

关键结论：

- Flash attention（einsum→SDPA）贡献约 **+77% 吞吐**，内存 -22%（2004→1566 MB）
- Triton 投影融合（SDPA→FlashSVD）贡献额外 **-55% 内存**（1566→708 MB），但吞吐略降 ~5%
- FlashSVD 相对 Naive(einsum) 综合效果：**+73% 吞吐**，**-64.7% 内存**
- SDPA 吞吐（~346 sps）略高于 FlashSVD（~332 sps）：Triton kernel 融合节省内存但引入少量计算开销





Activation memory is estimated as: peak memory – parameter footprint, where parameter footprint = total parameters × 4 bytes (fp32). Peak memory is measured via `torch.cuda.max_memory_allocated()`. Since measurement is taken at inference time, optimizer states are absent; minor allocator overhead may introduce small deviation.

Full-matrix ra312 vs Per-head ra48 (stage1, 无微调) 精度对比

两种配置参数量相同 (param_ratio≈0.5275, total≈0.6334)

Task	Dense	SVD-PH	SVD-FM	FWSVD-PH	FWSVD-FM	DRONE-PH	DRONE-FM	AdaSVD-PH	AdaSVD-FM
CoLA (MCC)	0.534	0.026	-0.018	0.144	0.188	0.016	0.078	0.002	-0.004
SST-2 (Acc)	0.924	0.718	0.783	0.778	0.825	0.856	0.847	0.614	0.620
MRPC (F1)	0.913	0.000	0.365	0.372	0.803	0.847	0.834	0.000	0.129
QQP (F1)	0.878	0.172	0.590	0.680	0.586	0.762	0.714	0.515	0.558
MNLI-m (Acc)	0.846	0.374	0.366	0.522	0.493	0.579	0.596	0.349	0.330
QNLI (Acc)	0.915	0.546	0.387	0.573	0.517	0.602	0.566	0.458	0.461
RTE (Acc)	0.726	0.473	0.545	0.585	0.542	0.596	0.578	0.534	0.599
STS-B (Pearson)	0.880	0.352	0.345	0.693	0.636	0.493	0.622	0.637	0.503
G-AVG	0.827	0.333	0.421	0.543	0.574	0.594	0.604	0.389	0.400
A-AVG	0.853	0.528	0.520	0.615	0.594	0.658	0.647	0.489	0.503

关键观察:

① MRPC: 全矩阵 vs 逐头的结构性差异

MRPC 是差距最大的任务 (SVD: 0.000 → 0.365; FWSVD: 0.372 → 0.803) , 根因是两种模式的信息瓶颈结构不同:

模式	Q 的压缩方式	头间语义
per_head	对每头 W_Q [768×64] 单独 SVD, 768→48 per head	各头独立, 无跨头共享
full	对整个 W_Q [768×768] 做 SVD, 768→r 全局子空间	所有头共享同一个 r 维输入投影

per_head 每头的输入压缩到 48 维 (保留 75%) , 各头在**独立**的小子空间内运作; full-matrix 所有头共享同一个 r 维全局子空间, 保留跨头的语义协作能力。

MRPC (句对语义等价判断) 对多头协作要求高——模型需联合多头捕捉两句话的细粒度差异。per-head 截断各头独立工作, 联合表达能力损失更多, 导致 collapse (全预测负类, F1=0) 。这也解释了为何 FWSVD 在同样 per-head 配置下仅得 0.372: 数据感知加权虽然比 SVD 好, 但无法弥补 per-head 的结构性跨头信息损失。

② MRPC per-head F1=0 是 collapse, 不是代码 bug

naive F1 == flashsvd F1 == 0 说明两个 backend 行为一致, collapse 由压缩方法本身造成。MRPC 的三重脆弱性叠加: 小验证集 (408 samples) + 类别不平衡 (正:负 ≈ 68:32) + F1 对全预测负类输出为 0 (而 Accuracy 此时仍有 ~32%) 。

③ SVD QQP: 全矩阵提升明显 (0.172 → 0.590) , 但 FWSVD 反而下降 (0.680 → 0.586)


plain SVD 在 full-matrix 下提升显著, 因为 768 维全局子空间比 per-head 独立 48 维更好地保留了任务相关方向。FWSVD 在 per-head 已经通过激活统计权重保留了关键方向 (0.680) , 切换到 full-matrix 后 Fisher 权重的跨头平均可能反而损失了某些头特定的重要方向。


④ DRONE 全矩阵无明显优势

DRONE 协方差校准在 per-head 模式下已能有效捕捉各头内部的激活分布, full-matrix 并无系统性提升 (QNLI 甚至略降: 0.602 → 0.566) 。

⑤ AdaSVD 全矩阵 MRPC 仍未恢复 (0.000 → 0.129)

ARS 以全矩阵语义分配 rank, budget=0.527 下某些层 Q rank 过低 (ARS 可能把更多 budget 分给 FFN) , 仍导致 MRPC collapse。但 RTE 明显改善 (0.534 → 0.599) ——RTE 可能受益于全局子空间的跨头语义保留。





Full-matrix ra312 性能对比 (stage1, naive backend)

Method	Latency (ms)	Throughput (sps)	Mem (MB)	vs Per-head 速度	vs Per-head 内存
SVD	~157-163	~196-200	2002	相近	相近
FWSVD	~153-159	~201-204	2010	相近	相近
DRONE	~157-163	~195-199	2002	相近	相近
AdaSVD	~100-108	~297-309	~1355	+70% 更快	-46% 更省

AdaSVD 全矩阵 vs 逐头的性能差异： full-matrix 模式下 ARS 对整个 W_q [768×768] 分配秩，选出的压缩秩结构导致推理时张量形状不同，内存从 ~2519 MB 降至 ~1355 MB (-46%)，延迟从 ~167 ms 降至 ~103 ms (+62% 加速)，尽管两者 param_ratio 相同 (~0.527)。

Full-matrix ra312 stage2 (压缩后微调) ——SVD 部分结果 (待补充)

Task	SVD-PH-ft	SVD-FM-ft	Δ(FM-PH)
CoLA (MCC)	0.374585	0.467440	+0.093
SST-2 (Acc)	0.910550	0.910550	+0.000
MRPC (F1)	0.843333	0.883562	+0.040
QQP (F1)	0.872762	0.876640	+0.004
MNLI-m (Acc)	0.820071	—	—
QNLI (Acc)	0.889072	—	—
RTE (Acc)	0.613718	—	—
STS-B (Pearson)	0.865878	—	—

FWSVD / DRONE / AdaSVD full-matrix stage2 待跑。

